인공지능 응용 프로젝트 · 4조

유튜브 댓글 감성분석 파이프라인

CNN / LSTM / Bi-LSTM 모델 비교 연구

팀명
4조

팀원
김한별 · 김준수

TASK
Binary Sentiment

LANGUAGE
Korean NLP

1 프로젝트 개요

본 프로젝트는 유튜브에서 수집한 한국어 댓글을 대상으로 **긍정(Positive) / 부정(Negative) 이진 감성분석**을 수행하는 딥러닝 파이프라인을 구축하고, 세 가지 텍스트 분류 모델(CNN, LSTM, Bi-LSTM)의 성능을 비교 분석하였습니다.

3	5,000	70 / 15 / 15	Okt
비교 모델	어휘 사전 크기	Train/Valid/Test 비율	한국어 형태소 분석기

2 전체 파이프라인 구조

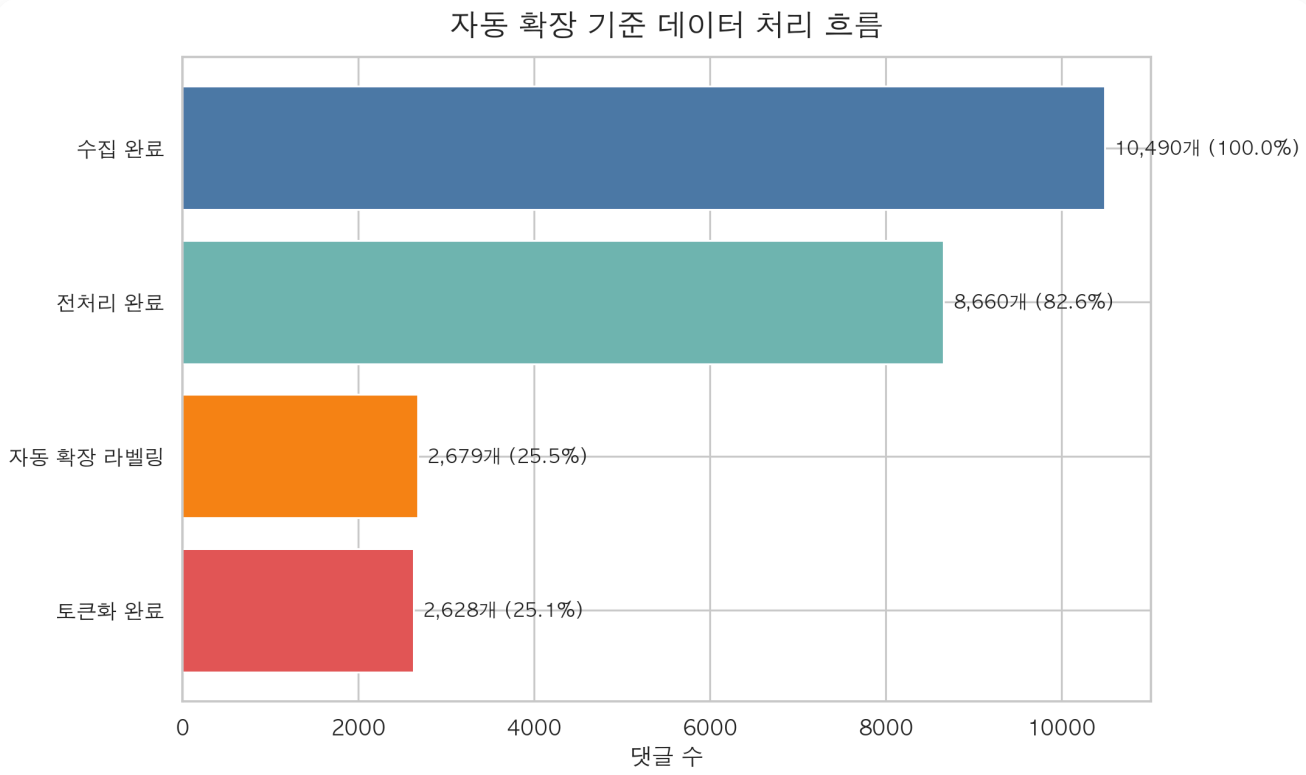

[Figure 1] 데이터 처리 단계별 퍼널 — 수집 댓글이 전처리·한국어 필터링·토큰화를 거치며 학습 가능한 형태로 축소되는 과정

3 데이터 수집 및 전처리

📌 전처리 단계

- HTML 태그 제거 **<.*?>**
- URL 제거 **http[s]?://**
- 멘션 제거 **@username**
- 한글·영문·숫자 외 문자 제거
- 연속 공백 정규화
- 한국어 포함 댓글만 유지

🔤 형태소 분석 (Okt)

- 추출 품사: **Noun** **Adjective** **Verb**
- 정규화(norm=True) + 어간 추출 (stem=True)
- 2글자 이상 토큰만 사용
- 불용어 18개 제거
- (진짜·너무·정말·댓글·영상 등)

> 💡 **라벨링 전략: 자동 확장 우선 사용**
>
> `auto_full_results/comments_labeled_auto_full.csv`가 존재하면 우선 사용하고, 없으면 수동 라벨 파일(`comments_labeled.csv`)을 사용합니다. 이를 통해 소규모 수동 라벨에서 대규모 학습 데이터로 확장할 수 있습니다.

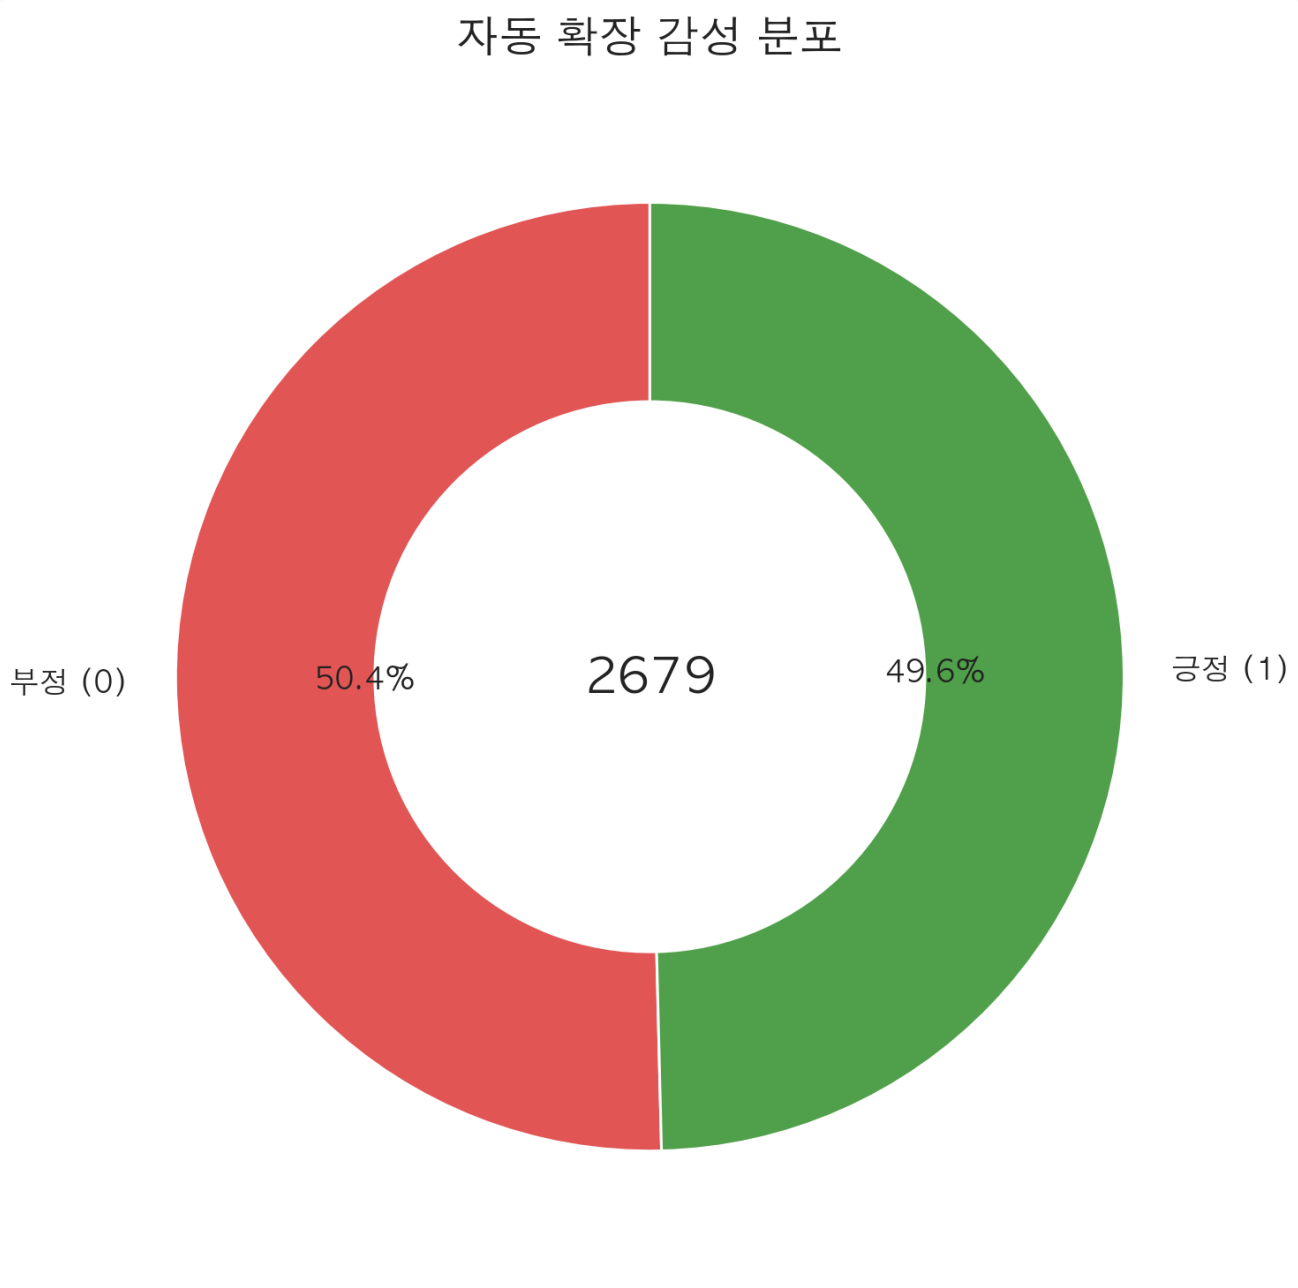

[Figure 2] 라벨링 데이터의 긍정/부정 분포 — 클래스 불균형 여부를 시각적으로 확인

4 딥러닝 모델 구조

공통 하이퍼파라미터

Vocab Size: 5,000 | Embed Dim: 64 | Learning Rate: 1e-3 | Batch Size: 32 | Max Epochs: 12

Optimizer: Adam | Loss: Binary Crossentropy | EarlyStopping: patience=3

◆ CNN 모델

◆ LSTM 모델

```
Embedding(vocab, 64,
input_length)
Conv1D(128, kernel=5,
relu)
GlobalMaxPooling1D()
Dense(64, relu)
Dropout(0.3)
Dense(1, sigmoid)
```

Conv1D로 지역적 n-gram 패턴을 포착. 학습 속도가 빠르며 단기 패턴에 강점.

```
Embedding(vocab, 64,
input_length)
LSTM(64)
Dense(32, relu)
Dropout(0.3)
Dense(1, sigmoid)
```

순방향 시퀀스 의존성 학습. 장거리 문맥 파악에 유리한 순환 구조.

▲ Bi-LSTM 모델

```
Embedding(vocab, 64, input_length)
Bidirectional(LSTM(64)) # 순방향 + 역방향 = 128dim
Dense(32, relu)
Dropout(0.3)
Dense(1, sigmoid)
```

양방향 문맥을 동시에 학습해 문장 전체의 의미를 더 풍부하게 포착. 세 모델 중 가장 많은 파라미터를 사용.

5 학습 결과 및 모델 성능 비교

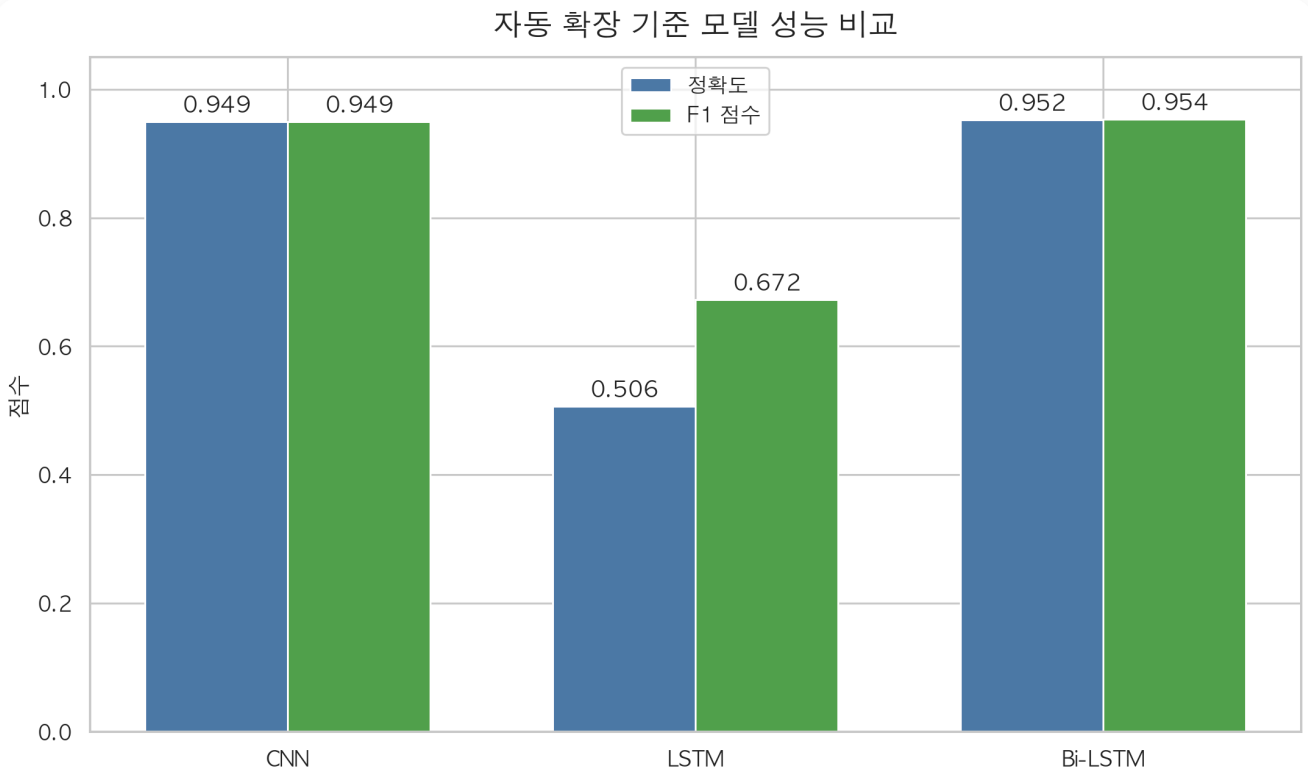

[Figure 3] CNN / LSTM / Bi-LSTM 테스트 정확도 및 F1-Score 비교

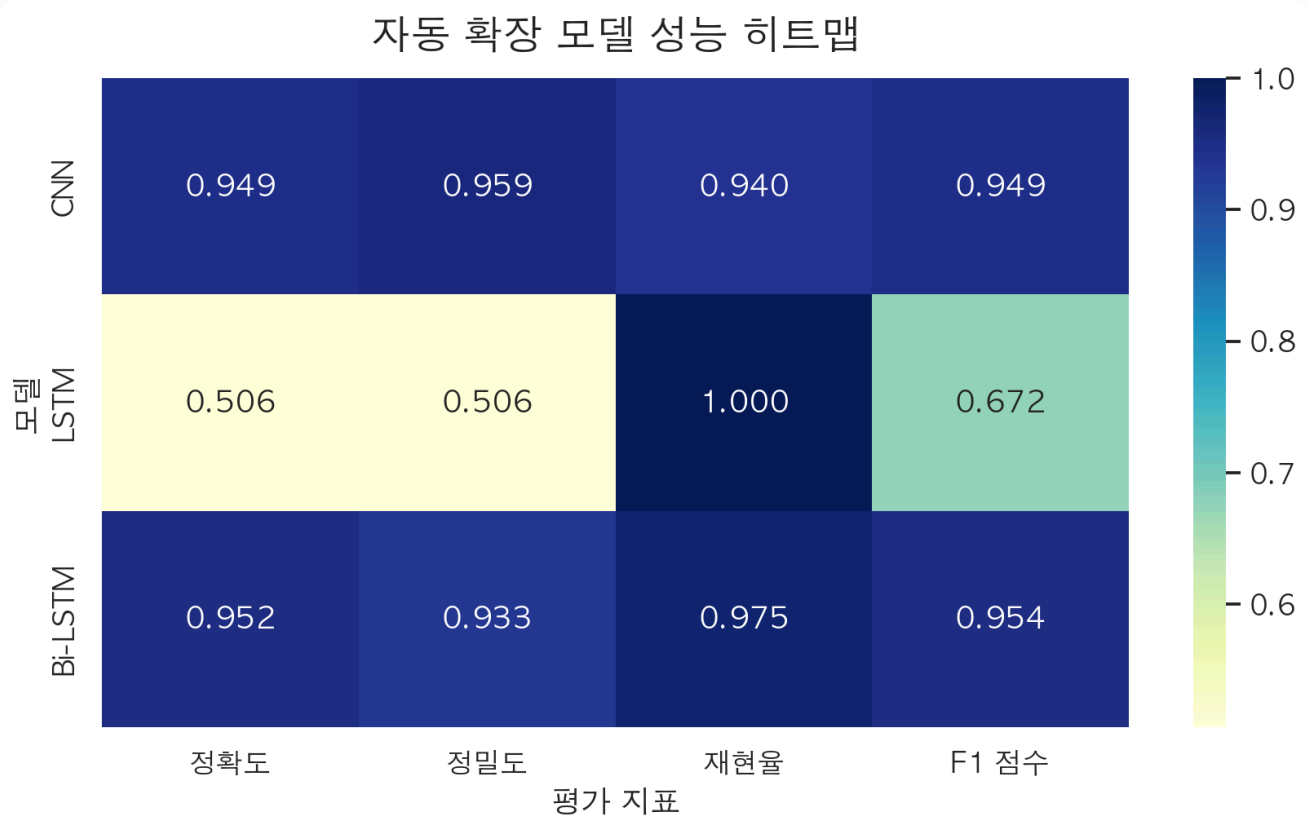

[Figure 4] 모델별 Accuracy · Precision · Recall · F1-Score 히트맵 — 지표 간 상대적 강약점 한눈에 비교

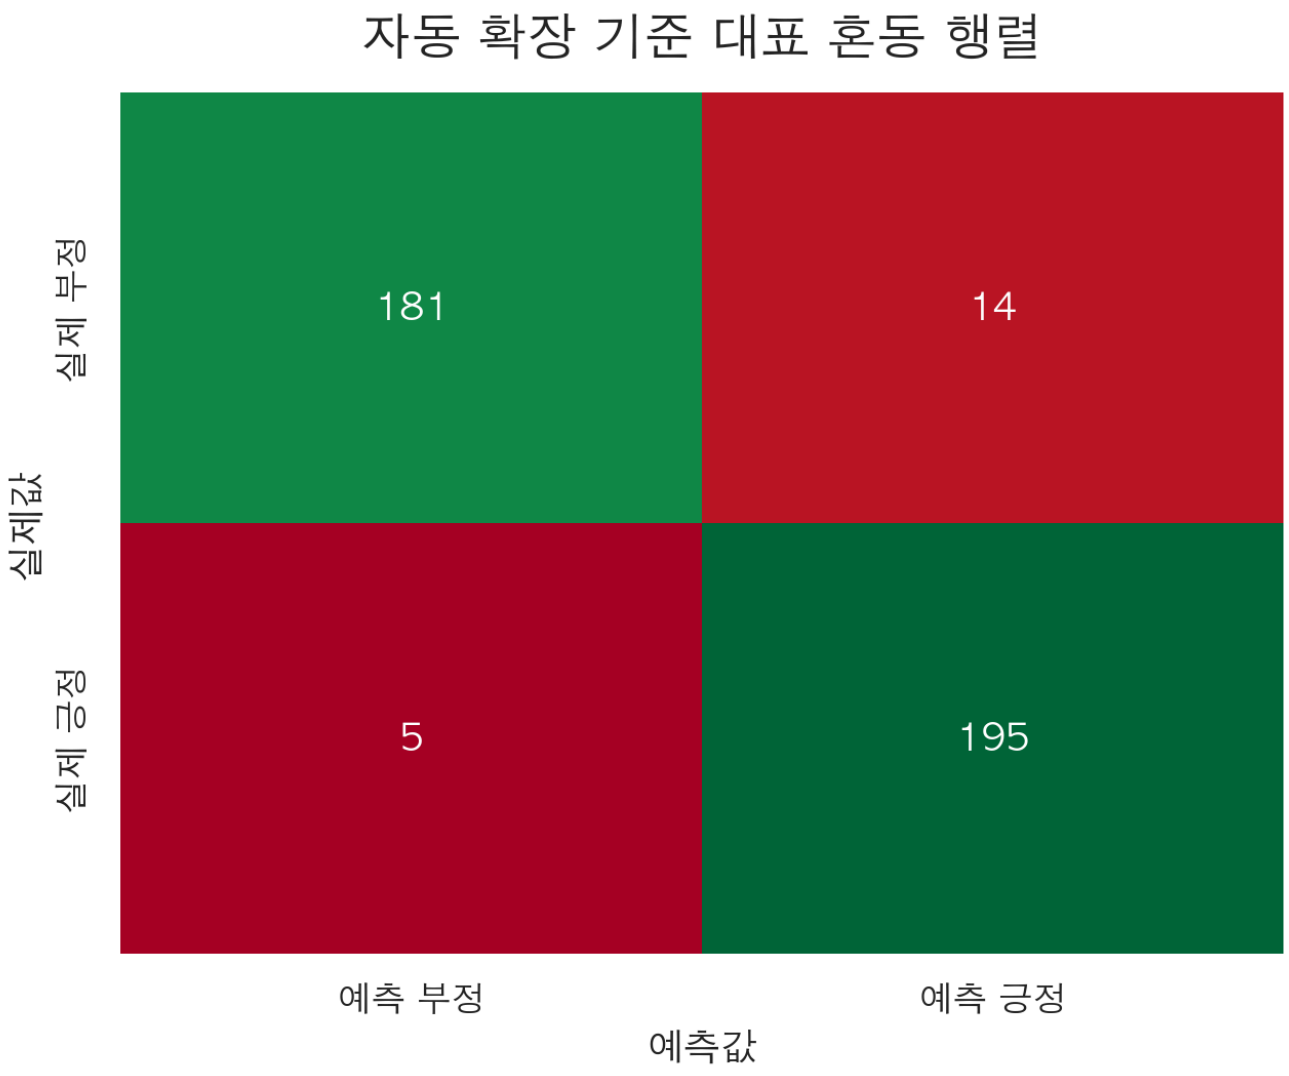

[Figure 5] 최고 성능 모델의 혼동 행렬(Confusion Matrix) — TP/TN/FP/FN 분포

📋 모델 성능 요약표 (Test Set 기준)

모델	Accuracy	Precision	Recall	F1-Score	학습 전략
CNN	—	—	—	—	지역 패턴 포착
LSTM	—	—	—	—	순방향 시퀀스
Bi-LSTM	—	—	—	—	양방향 문맥

※ 실행 결과값은 위 시각화 차트(Figure 3, 4) 참조

6 감성 분석 심화 분석

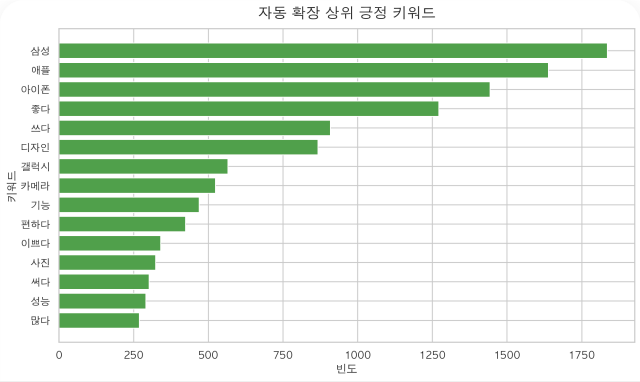

[Figure 6] 긍정 댓글 주요 키워드

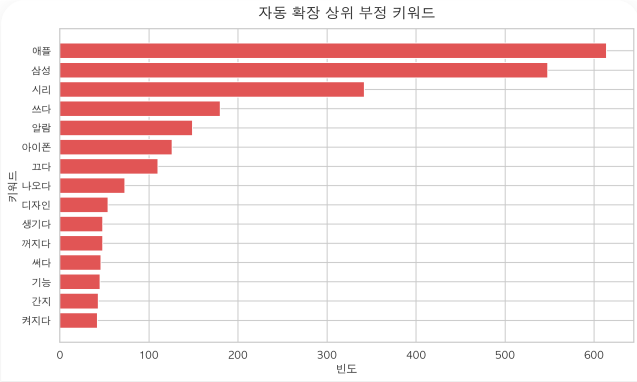

[Figure 7] 부정 댓글 주요 키워드

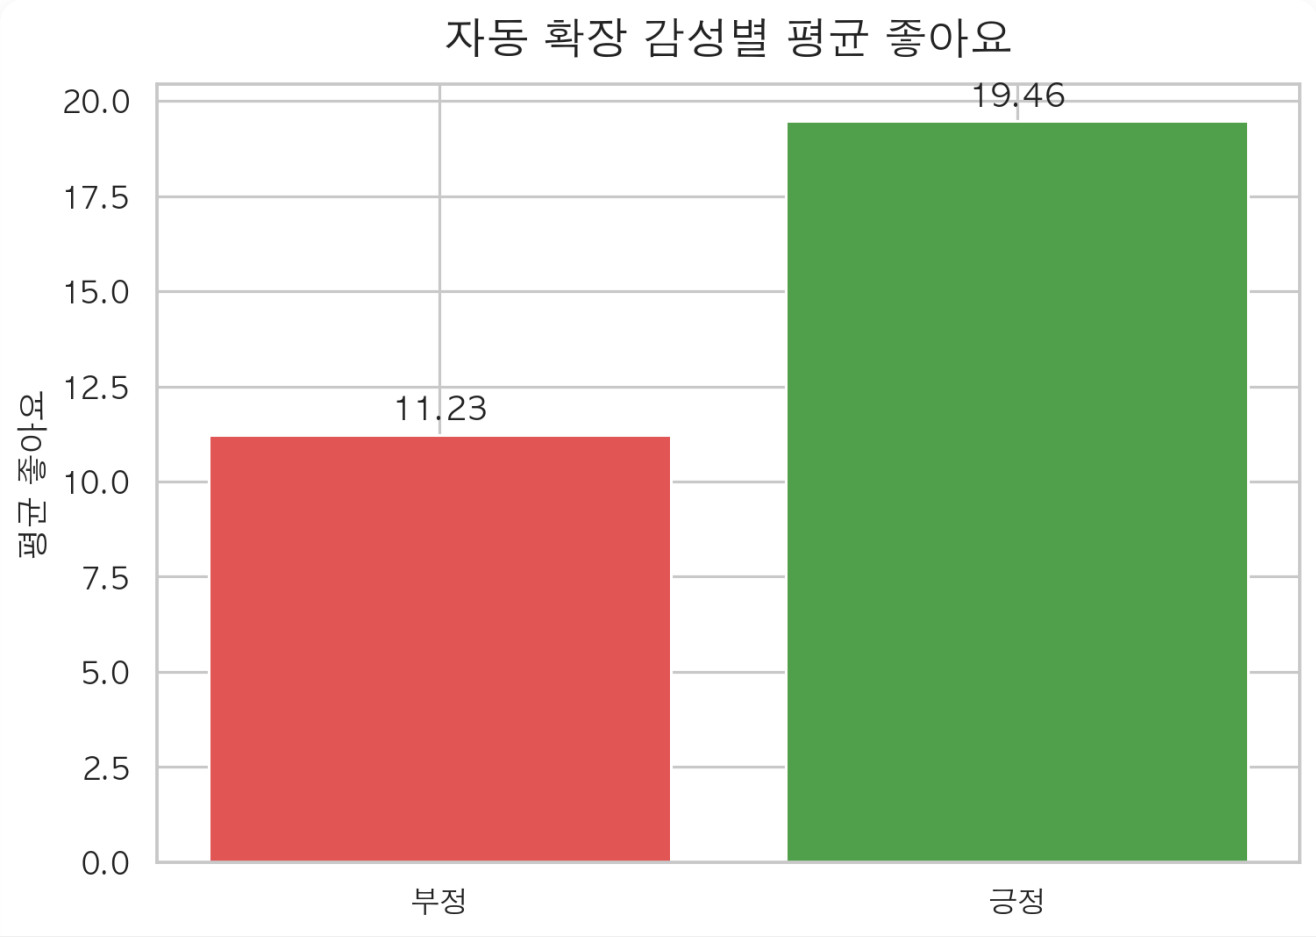

[Figure 8] 감성 유형별 평균 좋아요 수 — 긍정/부정 댓글의 사용자 반응 차이 분석

7 댓글 시계열 트렌드 분석

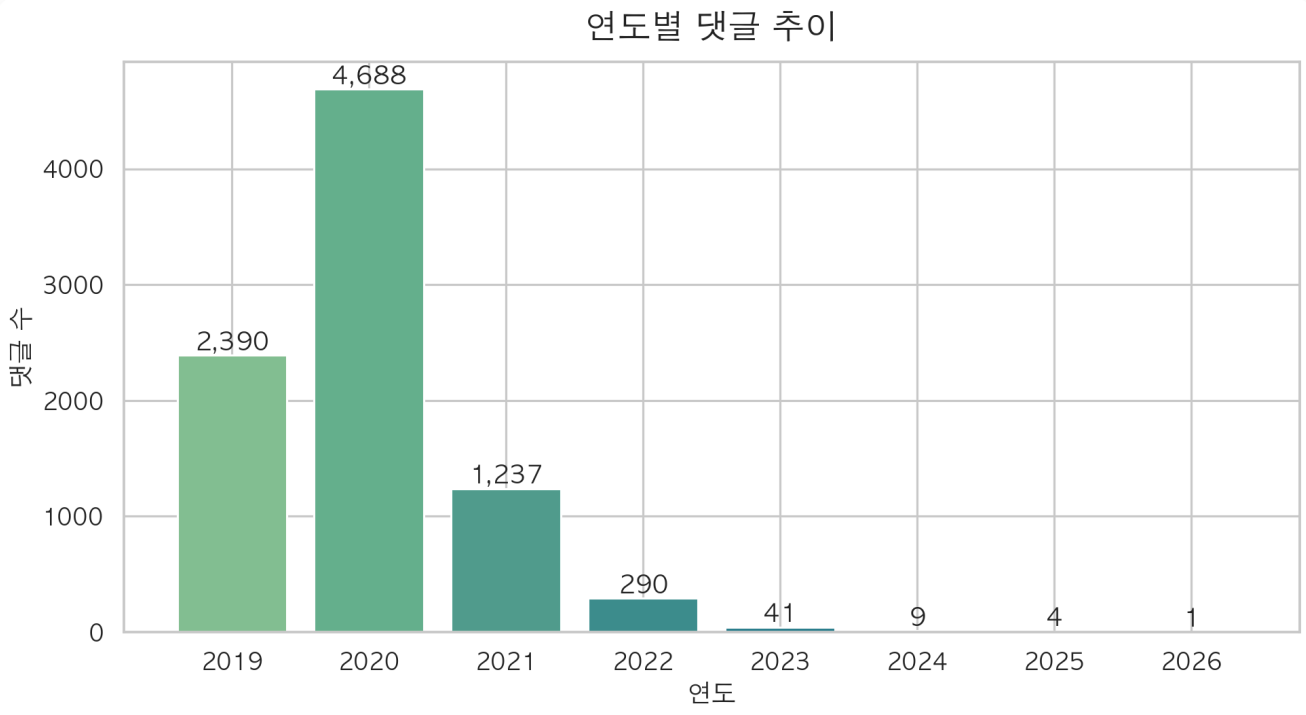

[Figure 9] 연도별 댓글 수 및 감성 트렌드 변화

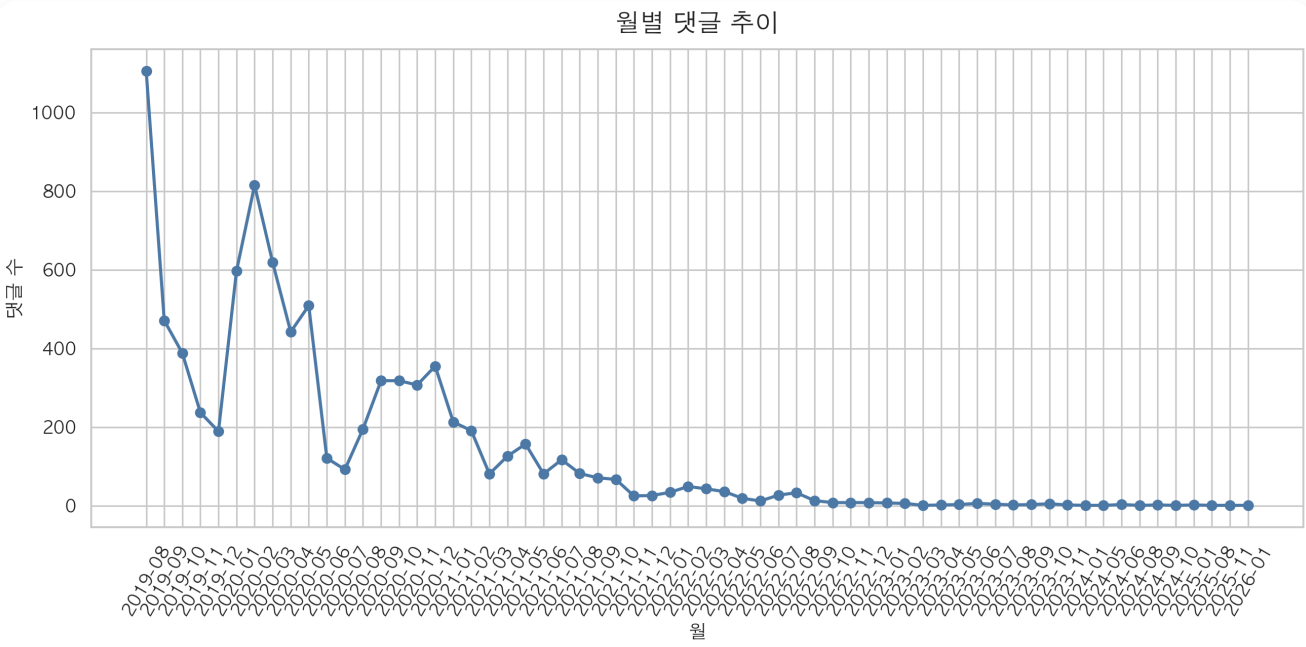

[Figure 10] 월별 댓글 수 및 감성 트렌드 — 계절적 패턴 및 이벤트 영향 파악

8 결론 및 시사점

✅ **주요 성과**

- 한국어 댓글 전처리 파이프라인 자동화
- Okt 기반 품사 필터링으로 노이즈 제거

🔍 **한계 및 개선 방향**

- 라벨 품질이 자동 확장에 의존

- 자동 확장 라벨링으로 학습 데이터 확충
- 세 모델 성능 체계적 비교 및 저장

- BERT/KoELECTRA 등 사전학습 모델 미적용
- 클래스 불균형 처리 추가 검토 필요
- 도메인 특화 불용어 사전 확장 여지

📝 종합 요약

본 프로젝트는 유튜브 한국어 댓글에 대한 감성분석 파이프라인을 구축하여
CNN, LSTM, Bi-LSTM 세 모델의 이진 분류 성능을 체계적으로 비교하였습니다.

Okt 형태소 분석기를 활용한 품사 기반 토큰화와 자동 라벨 확장 전략을 통해
한국어 텍스트의 특수성을 효과적으로 처리하였으며,
EarlyStopping을 적용해 과적합을 방지하고 최적 모델 가중치를 보존하였습니다.